

Université Ibn Tofaïl

Faculté des Sciences

Filière Master : Informatique et Intelligence Artificielle

PROJET DE FIN D'ÉTUDES

(PFE)

Système Intelligent de Surveillance
Industrielle
en Temps Réel Basé sur la Vision par
Ordinateur

Réalisé par :

Hicham JABBAD

Encadré par :

Mme Soukaina SRAIDI

Année universitaire : 2025 – 2026

Table des matières

1	Résumé	3
2	État de l'art	3
2.1	Traitement vidéo en temps réel et vision par ordinateur	3
2.2	Détection des accidents et des comportements anormaux basée sur l'IA . .	4
2.3	Système de gestion d'alerte et de surveillance en temps réel	5

Table des figures

1 Résumé

Cette revue de la littérature examine trois piliers centraux de la surveillance industrielle intelligente : la vision par ordinateur en temps réel pour le contrôle qualité et le suivi des processus, la détection des accidents et des comportements anormaux basée sur l'IA, ainsi que les systèmes de gestion d'alerte et de surveillance en temps réel. La synthèse met en évidence le passage de la vision industrielle traditionnelle aux architectures d'apprentissage profond, l'importance de l'informatique en périphérie pour l'inférence à faible latence, les techniques de fusion multimodale, et les défis liés au déploiement de systèmes robustes et adaptatifs dans des environnements industriels dynamiques. Les lacunes de recherche ouvertes incluent l'absence de références standardisées dans des conditions défavorables, la rareté des études de terrain longitudinales, et l'insuffisance des pratiques de gestion du cycle de vie pour le réentraînement des modèles et l'adaptation à la dérive.

2 État de l'art

2.1 Traitement vidéo en temps réel et vision par ordinateur

La convergence de la vision par ordinateur (CV) avec l'automatisation industrielle a fondamentalement remodelé le paysage de la surveillance en temps réel dans le secteur manufacturier et les infrastructures critiques. Contrairement aux systèmes de vision industrielle traditionnels qui reposaient sur des caractéristiques conçues manuellement et une logique basée sur des règles, les approches modernes exploitent des architectures d'apprentissage profond pour extraire des caractéristiques spatiales hiérarchiques directement à partir de flux vidéo bruts. Ce changement de paradigme a été largement motivé par les réseaux neuronaux convolutifs (CNN) et, plus récemment, par les modèles basés sur les transformeurs, qui offrent une capacité accrue à capturer les dépendances à longue portée dans les séquences d'images. Comme le soulignent plusieurs synthèses [1, 2], la progression d'architectures de type AlexNet vers des modèles légers tels que MobileNet et ShuffleNet a rendu l'inférence sur appareil faisable, réduisant ainsi la dépendance aux serveurs cloud distants. L'accent s'est déplacé du traitement par lots hors ligne vers une analyse continue et à faible latence des flux de caméras, une nécessité pour les environnements industriels dynamiques où les lignes de production fonctionnent à grande vitesse et où les écarts inattendus doivent être signalés en quelques millisecondes.

Une implémentation représentative dans l'industrie de l'éclairage montre comment la CV en temps réel peut remplacer l'inspection visuelle manuelle [3]. Dans ce cas, un algorithme de mise en correspondance de formes intégré dans un environnement LabVIEW vérifie automatiquement la présence et l'intégrité des filaments dans les ampoules à incandescence. Des cadres plus avancés intègrent des pipelines détecteur-suiveur pour des tâches telles que le comptage de véhicules aux intersections ou la surveillance des activités des travailleurs sur les chaînes d'assemblage [4, 5]. Ce dernier utilise YOLOv4-tiny pour classer les sous-opérations (par exemple, saisie de composant, fixation) puis applique un compteur à fenêtre glissante pour segmenter les cycles manuels de longue durée, comblant ainsi efficacement le fossé entre la détection d'objets et le raisonnement temporel.

Le déploiement de la CV dans les environnements industriels est toutefois soumis à des contraintes temps réel strictes qui dépassent la seule précision. Le débit soutenu en images par seconde, la latence de bout en bout entre la capture d'image et la décision de sortie, ainsi que la consommation d'énergie sur les appareils périphériques sont des

métriques critiques que de nombreux prototypes de recherche ne rapportent pas de manière cohérente [6]. Ce manque de télémétrie normalisée entrave la comparabilité entre les études et complique la traduction des avancées algorithmiques en systèmes opérationnels. Pour remédier à ces problèmes, des travaux récents préconisent l'utilisation de techniques d'optimisation adaptées au matériel, y compris l'élagage de modèles, la quantification et la distillation des connaissances [2, 7]. Par exemple, un MobileNetV2 quantifié déployé sur un NVIDIA Jetson Nano a atteint un débit de 30 FPS avec une précision de classification de 97,6 % pour la détection de défauts de surface métallique, démontrant que des CNN légers peuvent répondre aux exigences temps réel sans sacrifier la précision. De plus, l'intégration de l'informatique en périphérie avec la vérification dans le cloud a émergé comme une architecture hybride qui équilibre la latence et les coûts de fausse alarme : les alertes critiques sont générées localement, tandis que les données moins urgentes sont déchargées pour une analyse par lots [8, 9].

Une autre avancée significative est la fusion de la vision avec d'autres modalités de détection. Les approches multimodales qui combinent des caméras RVB avec des capteurs IoT — tels que des accéléromètres, des compteurs de courant et des thermistances — fournissent une vue plus holistique de l'environnement de production [10]. Dans de tels systèmes, une architecture d'apprentissage profond à deux flux traite les caractéristiques spatiales via un CNN ResNet-50 tout en capturant simultanément la dynamique temporelle des données des capteurs à l'aide d'une unité récurrente bidirectionnelle à portes (BiGRU). La fusion de ces flux a amélioré la précision de la reconnaissance d'actions de 88,4 % (vision seule) à 95,7 %, soulignant la valeur de l'intégration d'informations complémentaires. Néanmoins, des défis persistent en matière de synchronisation des données, d'étalonnage des capteurs et de capacité à fonctionner dans des conditions défavorables telles qu'un mauvais éclairage, des occlusions ou des changements saisonniers. Les tests de robustesse sous variabilité terrain — incluant nuit, brouillard et flou de mouvement — sont encore rarement rapportés, ce qui limite la généralisabilité des systèmes actuels [6].

2.2 Détection des accidents et des comportements anormaux basée sur l'IA

L'automatisme de reconnaissance des événements dangereux et des actions humaines anormales constitue un deuxième pilier majeur de la surveillance industrielle intelligente. Contrairement aux mécanismes de sécurité traditionnels qui reposent sur l'observation manuelle ou des déclencheurs simples basés sur des seuils, les approches pilotées par l'IA analysent en continu les flux vidéo pour identifier des schémas comportementaux subtils précédant les accidents. Cette capacité est particulièrement critique dans les secteurs à haut risque tels que les mines, la construction et la fabrication lourde, où les incidents par heurt, les chutes et les entrées en zones non autorisées sont des causes fréquentes de blessures. Le passage de l'investigation a posteriori à l'intervention proactive a été rendu possible par des modèles d'apprentissage profond capables de détecter non seulement la conformité aux équipements de protection individuelle (EPI), mais aussi les interactions dynamiques entre les travailleurs et les machines.

L'une des techniques les plus largement adoptées pour la détection de comportements anormaux est la famille de détecteurs d'objets YOLO, en raison de son équilibre favorable entre vitesse et précision. Dans un déploiement pour la sécurité dans une mine de molybdène, un système collaboratif en périphérie-cloud basé sur YOLOv8 effectue une reconnaissance faciale en temps réel, une détection des casques de sécurité et une sur-

veillance de distance pour les opérations à chaud [11]. L’architecture intègre Node-RED pour l’orchestration de processus à faible code, EdgeX pour la gestion unifiée des périphériques et EMQX pour le courtage de messages à haut débit. En plaçant l’inférence en périphérie, le système atteint une latence de réponse inférieure à une seconde tout en préservant la bande passante pour la journalisation centralisée et la diffusion des alertes. De même, pour la détection de violence dans les réseaux de surveillance industrielle, une combinaison de mémoire à long terme et court terme convolutive (ConvLSTM) et d’unités récurrentes à portes (GRU) a été proposée pour encoder les caractéristiques spatiotemporelles des séquences vidéo, atteignant une précision de 98,5 % sur l’ensemble de données hockey fight et de 88,2 % sur des séquences de surveillance réelles [8].

Au-delà de l’analyse monomodale, la détection d’anomalies multimodale a gagné du terrain pour sa capacité à corrélérer les indices visuels avec les signaux acoustiques ou vibratoires. Dans le contexte des opérations de meules, un cadre qui traite simultanément les coefficients cepstraux de fréquence Mel (MFCC) provenant de l’audio et les trames d’image provenant de la vidéo a été développé [12]. Un autoencodeur prétraite les caractéristiques audio, tandis qu’un ConvLSTM capture les dépendances temporelles dans le flux vidéo ; la modalité combinée donne un score F1 de détection de 0,836, surpassant significativement chaque modalité seule. Ce résultat souligne que les anomalies industrielles se manifestent souvent sur plusieurs canaux sensoriels et que les techniques de fusion peuvent compenser les limites des sources de données individuelles — par exemple, en cas d’occlusions visuelles ou lorsque les signatures acoustiques sont noyées dans le bruit de fond.

Malgré ces progrès, plusieurs défis ouverts persistent. La rareté d’ensembles de données d’anomalies industrielles bien annotées, en particulier pour des événements rares tels que les défaillances d’équipement ou les blessures graves, entrave l’entraînement de modèles généralisables. De nombreuses références existantes (par exemple, SWaT, HAI, UCF Crime) sont soit orientées processus, soit focalisées sur la surveillance générale, manquant d’annotations spécifiques au domaine pour les contextes de construction ou de fabrication [6]. En outre, la dérive du concept — le changement graduel du comportement normal dû aux variations d’éclairage, aux saisons ou aux flux de production — reste peu explorée. La plupart des modèles de détection sont entraînés sur des ensembles de données statiques et ne sont pas conçus pour s’adapter en ligne, ce qui entraîne une dégradation des performances au fil du temps. Des techniques telles que l’apprentissage incrémental, l’apprentissage fédéré et l’apprentissage actif ont été proposées pour atténuer ce problème, mais leur déploiement dans des environnements industriels réels est encore naissant [6, 9].

2.3 Système de gestion d’alerte et de surveillance en temps réel

La troisième dimension de la surveillance industrielle intelligente concerne l’orchestration des alertes, des tableaux de bord de visualisation et l’intégration avec les technologies opérationnelles (OT) existantes. Un algorithme de détection, aussi précis soit-il, a une valeur limitée si ses résultats n’atteignent pas le bon décideur en temps utile et de manière actionnable. Par conséquent, la recherche contemporaine s’est concentrée sur la conception de pipelines de bout en bout qui couplent des modules de perception avec des moteurs de règles, des contrôleurs de dispositifs et des interfaces homme-machine (IHM). Ces systèmes doivent équilibrer la sensibilité (pour éviter de manquer des dangers réels) et la spécificité (pour prévenir la fatigue d’alarme), tout en respectant les exigences de confidentialité et de gouvernance des données.

Une architecture prototype pour l’alerte en temps réel est le cadre collaboratif en périphérie-cloud mis en œuvre pour la surveillance des aires de trafic aéroportuaires [8]. Dans cette conception, une détection d’objets légère s’exécute sur des dispositifs périphériques pour signaler immédiatement les événements suspects (par exemple, personnel non autorisé sur le tarmac); le même nœud périphérique diffuse également la vidéo traitée vers un serveur cloud pour une vérification secondaire et un stockage à long terme. Cette approche à deux étapes réduit la charge de bande passante et permet des réponses locales rapides, tandis que la couche cloud fournit une piste d’audit et soutient le réentraînement du modèle. De même, dans le banc d’essai de fabrication intelligente décrit dans [10], les résultats de détection du modèle de fusion CNN-BiGRU sont acheminés vers un système d’exécution de la fabrication (MES) et affichés sur des tableaux de bord en direct construits avec Node-RED et Grafana. Les superviseurs reçoivent des métriques en temps réel sur l’achèvement des tâches, la santé des machines et les écarts ergonomiques, leur permettant d’intervenir avant qu’une inefficacité mineure ne se transforme en perturbation majeure.

La gestion des faux positifs et la conception d’interfaces d’alerte conviviales sont des thèmes récurrents dans la littérature. Les opérateurs industriels sont souvent submergés par des notifications à haute fréquence et faible certitude, ce qui conduit à une fatigue d’alarme et à un rejet éventuel du système. Pour contrer cela, certains systèmes intègrent directement une quantification de l’incertitude dans la logique d’alerte. Par exemple, un modèle d’apprentissage profond bayésien qui produit à la fois une prédiction et sa variance associée peut supprimer les alertes lorsque le modèle est incertain, demandant plutôt une vérification humaine [13]. De plus, des techniques d’explicabilité telles que SHAP (Shapley additive explanations) sont intégrées pour fournir aux opérateurs des explications visuelles de la raison pour laquelle un événement particulier a été signalé, favorisant ainsi la confiance et facilitant l’analyse des causes profondes [6, 13].

Un autre aspect critique est l’intégration transparente des alertes basées sur la vision avec les systèmes de contrôle industriels existants. Les environnements OT hérités reposent souvent sur des protocoles propriétaires et des IHM isolées, ce qui rend difficile l’injection d’alertes automatisées. Des travaux récents exploitent des normes ouvertes telles que OPC UA et MQTT pour combler le fossé entre les moteurs d’inférence IA et les automates programmables (PLC). Dans le système de sécurité minière [11], MQTT est utilisé pour publier des événements anormaux vers un courtier central, à partir duquel des règles Node-RED déclenchent des actions spécifiques — comme déclencher une alarme sonore, envoyer un SMS au responsable de la sécurité ou arrêter un convoyeur. Cette architecture découplée et pilotée par les événements garantit que le système de surveillance n’interfère pas avec les boucles de contrôle critiques tout en fournissant des interventions rapides. En outre, l’intégration de jumeaux numériques a été explorée comme un moyen de visualiser les anomalies détectées dans une réplique tridimensionnelle de l’installation, permettant aux opérateurs d’explorer le contexte spatial d’une alerte [6].

Enfin, la gouvernance et la gestion du cycle de vie des systèmes de surveillance en temps réel sont apparues comme des sujets de recherche importants. Des normes telles que MLOps (machine learning operations) sont en cours d’adaptation aux environnements industriels pour traiter le versionnage des modèles, la détection de dérive et les stratégies de retour arrière. Une revue systématique récente [6] propose un cadre de mise en œuvre unifié qui impose la co-notification de la latence de bout en bout, du débit soutenu, de la consommation d’énergie et du contexte matériel — des métriques actuellement sous-rapportées mais essentielles pour les décisions de déploiement. La revue met

également l'accent sur les principes de confidentialité dès la conception, y compris la minimisation des données, le traitement sur l'appareil et les journaux d'accès vérifiables, qui sont de plus en plus exigés par des réglementations telles que le règlement européen sur l'IA. À mesure que les systèmes de surveillance intelligents deviennent plus omniprésents, la capacité à fonctionner de manière transparente et responsable sera aussi importante que leurs performances de détection brutes.

Références

- [1] A. Ettalibi, A. Elouadi, and A. Mansour. Ai and computer vision-based real-time quality control : A review of industrial applications. In *Procedia Computer Science*, volume 224, pages 1–9, 2023. 14th International Conference on Emerging Ubiquitous Systems and Pervasive Networks – EUSPN 2023.
- [2] D. Narsina, N. Richardson, A. Kamisetty, J. C. S. Gummadi, and K. Devarapu. Neural network architectures for real-time image and video processing applications. *Engineering International*, 10(2) :131–144, 2022.
- [3] C. K. Ng, C. H. Wu, W. H. Ip, C. Y. Chan, and G. T. S. Ho. A real time quality monitoring system for the lighting industry : A practical and rapid approach using computer vision and image processing tools. *Journal of Information Technology in Construction (ITcon)*, 19 :72–91, 2014.
- [4] P. Lou, J. Li, Y. Zeng, B. Chen, and X. Zhang. Real-time monitoring for manual operations with machine vision in smart manufacturing. *Journal of Manufacturing Systems*, 60 :662–675, 2021.
- [5] B. Coifman, D. Beymer, P. McLachlan, and J. Malik. A real-time computer vision system for vehicle tracking and traffic surveillance. *Transportation Research Part C : Emerging Technologies*, 6(4) :271–288, 1998.
- [6] A. Bello, A. S. Akintola, R. I. Abasiama, O. E. Esan, and O. A. Oluwaseun. Real-time computer vision for safety and efficiency in smart infrastructure : A systematic review. *Discover Artificial Intelligence*, 6(1) :62, 2026.
- [7] K. K. Pappula. Edge-deployed computer vision for real-time defect detection. *International Journal of Emerging Research in Engineering and Technology*, 4(2) :79–88, 2023.
- [8] F. U. M. Ullah, K. Muhammad, I. U. Haq, N. Khan, A. A. Heidari, S. W. Baik, and V. H. C. de Albuquerque. Ai-assisted edge vision for violence detection in iot-based industrial surveillance networks. *IEEE Transactions on Industrial Informatics*, 18(8) :5359–5368, 2022.
- [9] W. Villegas-Ch, J. Garcia-Ortiz, and S. Sanchez-Viteri. Toward intelligent monitoring in iot : Ai applications for real-time analysis and prediction. *IEEE Access*, 12 :45678–45695, 2024.
- [10] S. Omoley. Integration of computer vision and iot sensors for real-time performance monitoring in smart manufacturing systems. *International Journal of Advanced Manufacturing Technology*, 128 :4567–4582, 2025.

- [11] B. Zhang and Y. Lyu. Design and implementation of deep learning-based abnormal behavior detection system. *Journal of Internet Technology*, 27(1) :1–17, 2026.
- [12] Q. Zhang, H.-C. Chang, C.-L. Ho, H.-C. Keh, and D. Sinha Roy. Ai-based multimodal anomaly detection for industrial grinding wheel operations. *Journal of Internet Technology*, 26(2) :255–264, 2025.
- [13] A. K. M. Nor, S. R. Pedapati, M. Muhammad, and V. Leiva. Abnormality detection and failure prediction using explainable bayesian deep learning : Methodology and case study with industrial data. *Mathematics*, 10(4) :554, 2022.